


Linguagens de Programação para Engenharia de Dados

Professor: Cassio Pinheiro • <https://www.linkedin.com/in/cassio-pinheiro-9baa7939/>

Carga horária: 24h | Datas: 25/06 a 11/07/2026



Sumário da Disciplina

Módulo 1 — Fundamentos · Encontro 1 (25/06/2026)

- 1 O que é Engenharia de Dados — e como difere de Ciência de Dados
- 2 O dado como produto e por que programar (e não clicar)
- 3 O mapa das linguagens: Python, SQL e o papel de Scala/Java
- 4 Python na prática: blocos mínimos e estruturas de dados
- 5 Seu primeiro pipeline ETL + laboratório guiado

Objetivos da Disciplina

1

Papel do Engenheiro

Como a Engenharia de Dados se relaciona com Ciência de Dados, Analytics e o negócio.

2

Programação no centro

Por que programar é a competência central da Engenharia de Dados.

3

Mapa das linguagens

Python, SQL e o papel de Java/Scala — e quando cada uma entra.

4

Python aplicado

Ler e escrever trechos básicos de Python para manipular dados.

5

Pipeline ponta a ponta

Ingerir, transformar e persistir dados num mini-ETL completo.

Módulo 1 — Fundamentos — O que é Engenharia de Dados e por que programar

Encontro 1 • 25/06/2026

19:00 às 22:30

01

Antes de começar

Quem é a turma e como vamos trabalhar

Turma diversa

Há quem programe há anos e quem nunca programou — e está tudo certo.

Aula de fundação

Vocabulário, intuição e o primeiro código rodando hoje.

Aprende-se programando

A teoria existe para dar sentido ao código.

Pergunte sempre

Errar de propósito é parte do método.


O que é Engenharia de Dados

A base da pirâmide que sustenta a IA

Projeta, constrói e mantém os sistemas que movem e preparam dados.

Entrega dado **confiável**, na hora certa, no formato certo e de forma rastreável.

É **pré-requisito** de tudo que vem depois: análise, dashboards e IA.



A base sustenta tudo o que vem acima

Ciclo de vida do dado





**Se o dado é água, o engenheiro constrói o encanamento;
o cientista analisa o que a água revela.
Sem encanamento, não há análise.**



Engenharia de Dados × Ciência de Dados

Engenheiro de Dados

Pergunta-chave

“Como entrego este dado confiável, na hora certa?”

Entregáveis

Pipeline, tabela tratada, API de dados e data warehouse.

×

Cientista de Dados

Pergunta-chave

“O que este dado revela? O que consigo prever?”

Entregáveis

Modelo, análise, relatório e previsão.

A fronteira varia por empresa — mas sem dado confiável, não há ciência.

O dado como produto

A distância entre o CSV bruto e o dado em que se confia

- Dado é produto, não subproduto: tem dono, padrão de qualidade, documentação e consumidores.
- Garbage in, garbage out: o pipeline não conserta a fonte — só propaga o erro mais rápido.
- Validar cedo é barato; descobrir o erro tarde é caro.

Dado confiável é:



Do bruto ao confiável (com contrato)




Por que programar (e não clicar)



Automação

O processo roda sozinho, todo dia, sem ninguém clicando.



Reprodutibilidade

Mesmo código + mesmo dado = mesmo resultado, auditável.



Escala

O que funciona para mil linhas funciona para milhões.

Excel resolve o caso pequeno e único; **Engenharia de Dados vive do repetível em escala.**

O mapa das linguagens

Cada uma entra num momento — você não precisa de todas hoje

Python
NOSSO FOCO

A linguagem de cola: lê de tudo, transforma, integra, orchestra.

SQL

A língua franca dos dados estruturados. Inegociável na carreira.

Scala / Java

O motor das plataformas de larga escala (Spark, Hadoop).

Go · Rust · Bash

Nichos: alta performance, CLIs e automação de infraestrutura.

A pergunta certa não é “qual a melhor linguagem”, mas “qual entra agora”.

Compilada × Interpretada


Interpretada

Python

Velocidade de escrita



Velocidade de execução



Compilada

Java · Scala · C

Velocidade de escrita



Velocidade de execução



Usamos Python pela produtividade — com motores compilados por baixo quando o volume aperta. Ex.: o pandas faz o trabalho pesado em C otimizado.

Python: os blocos mínimos

Cada bloco é uma peça de pipeline

Variáveis e tipos

```
str · int · float · bool · None
```

None é o valor ausente, onipresente em dados

Condicionais

```
if / elif / else
```

Decidir o que fazer conforme o dado

Laços (loops)

```
for linha in arquivo:
```

Repetir sobre muitos itens — o coração do pipeline

Funções

```
def transformar(x): ...
```

Empacotar lógica com nome, para reutilizar e testar

Indentação não é estética em Python — é sintaxe.

Estruturas que todo pipeline usa

Lista

```
[10, 20, 30]
```

Sequência ordenada e mutável: linhas de um arquivo, lote de registros.

Dicionário

```
{"id": 1}
```

Pares chave:valor — um registro; a forma do JSON.

Tupla

```
(lat, lon)
```

Sequência imutável: coordenada, chave composta.

Conjunto (set)


```
{1, 2, 3}
```

Sem ordem e sem duplicatas: deduplicação de graça.

Uma lista de dicionários é a forma natural de uma tabela.

Seu primeiro pipeline: ETL

Onde tudo que vimos hoje converge



Extrair → Transformar → Carregar: o esqueleto que repetiremos o curso inteiro.

O que torna isto “engenharia”

Idempotência

Rodar duas vezes dá o mesmo resultado, sem duplicar dados.

Tratamento de erro

Fonte malformada falha de forma clara — não corrompe em silêncio.

Rastreabilidade

Conto quantas linhas entraram, saíram e por que cada uma foi descartada.

Observabilidade

O pipeline registra o que fez (logs) para eu confiar sem assistir rodar.

Um script roda uma vez; um pipeline roda muitas — de forma confiável.

Prática — Encontro 1

```
jupyter > <disciplina>_pratica.ipynb • seção: Encontro 1
```

- 1 Abrir o notebook e localizar a seção do Encontro 1.
- 2 Executar as células na ordem, de cima para baixo.
- 3 Dataset sintético é determinístico — CSV fixo, sem aleatoriedade.
- 4 Discussão dos resultados ao final.

Síntese do encontro

- 1 Engenharia de Dados constrói o encanamento confiável que alimenta análise, IA e negócio.
- 2 O dado é um produto: há distância real entre bruto e confiável — fechá-la é o nosso trabalho.
- 3 Programar dá automação, reprodutibilidade e escala.
- 4 Python é a cola central; SQL é inegociável; Scala/Java explicam o motor de larga escala.
- 5 Extrair → Transformar → Carregar é o esqueleto que vamos refinar e escalar.

Para o próximo encontro

Tarefa e preparação



Rode o notebook inteiro por conta própria; altere valores e observe o que muda.



Faça os exercícios — especialmente quebrar o pipeline de propósito e consertá-lo.



Traga um processo de dados do seu trabalho que hoje você faz na mão.



Vamos enxergá-lo juntos como um pipeline (Extrair → Transformar → Carregar).

Bibliografia



**Fundamentos de
Engenharia de
Dados**

Reis & Housley

O'Reilly / Alta Books · 2023



**Python para
Análise de Dados**

Wes McKinney

3ª edição · O'Reilly · 2022



**Designing Data-
Intensive
Applications**

Martin Kleppmann

O'Reilly · 2017



Unifor

Obrigado!

Cassio Pinheiro

in

[linkedin.com/in/cassio-pinheiro-9baa7939](https://www.linkedin.com/in/cassio-pinheiro-9baa7939)